第一人工作报告

研究机会的四把量尺

从表面距离到模型内部表征

KLab × arXiv 跨学科研究机会检测系统

AI Agents for Social Science — Final Project

2026年3月

1. 项目概述

本报告记录“第一人”在“Serendipity Agent”项目中的全部工作。核心任务是：建立一套多维度的“研究机会衡量尺”，用四种不同的计算方法来检测 KLab（University of Chicago Knowledge Lab）的研究与 arXiv 全库论文之间的跨学科研究机会。

四种量尺分别是：

量尺 1 — Embedding 距离：用 Sentence-BERT 计算 KLab 论文与 arXiv 论文之间的语义相似度，筛选“有共同语言但不在同一领域”的跨学科候选对。

量尺 2 — Perplexity 评分：用 GPT-2 和 Llama-3-8B 计算每篇 arXiv 论文对语言模型的“意外程度”，验证 Zhang & Evans (2025) 的理论。

量尺 3 — 时序收敛分析：追踪 2019–2026 年间 arXiv 各学科领域的 embedding 距离变化趋势，识别正在快速靠近的学科对。

量尺 4 — Steering Vector 打分：用 Contrastive Activation Addition (CAA) 从 Llama-3-8B 内部提取“跨学科性”方向向量，对每篇候选论文打分。

最终产出一个包含 242,253 个 KLab × arXiv 候选配对的综合评分表，供第二人（因果推断）、第三人（MCP 工具封装）、第四人（LoRA 微调 + 奖励模型）使用。

2. 数据获取与预处理

2.1 KLab 论文数据

数据来源

起始数据来自 paper_list.txt，包含 KLab 实验室近年发表的全部论文列表，格式为：年份 | 引用数 | 标题 | 期刊 | DOI。

OpenAlex API 获取流程

使用 fetch_klab_papers.py 脚本通过 OpenAlex API 获取每篇论文的完整元数据：

Step 1 解析：从 paper_list.txt 提取标题、DOI、年份、引用数。原始解析约 500 条记录。

Step 2 去重：按 DOI 和标题去重，得到约 460 篇唯一论文。

Step 3 API 查询：优先用 DOI 查询，失败则回退到标题搜索。成功获取 451 篇。

Step 4 元数据提取：从返回结果中提取 title、abstract（通过反转索引重建）、concepts、topics、cited_by_count 等字段。

数据损失说明

原始约 500 篇 → 去重后 460 篇 → API 成功 451 篇。有 9 篇因为 DOI 无效且标题搜索也未命中而缺失。

在后续 Embedding 计算时，只有 332 篇通过了 klab_metadata.pkl 的筛选（该文件缺失了部分论文的摘要文本，仅保存了 abstract_length）。最终参与候选配对的 KLab 论文为 326 篇。

2.2 arXiv 论文数据

数据源：Kaggle arxiv-metadata-oai-snapshot.json，包含约 297 万篇 arXiv 论文的元数据（标题、摘要、分类、更新日期）。

字段使用：id, title, abstract, categories, update_date。无引用数数据。

3. 量尺 1：Embedding 距离

3.1 模型选择

使用 all-MiniLM-L6-v2 (384D) 而非课程指定的 distilbert-base-nli-stsb-mean-tokens (768D)。原因：

- 计算效率：22M 参数 vs 66M，内存占用更小
- 性能相当：STSB 任务上 84.25 vs 85.16，差异很小

3.2 实现流程

Step 1 — KLab Embedding（本地 CPU）：对 332 篇 KLab 论文的摘要计算 384 维 embedding，保存为 klab_embeddings.npz。

Step 2 — arXiv Embedding（Colab GPU）：对 2,967,989 篇 arXiv 论文摘要计算 embedding，保存为 arxiv_embeddings.npz。

Step 3 — 相似度计算 + 筛选：对每篇 KLab 论文，计算与所有 arXiv 论文的余弦相似度，筛选 cosine similarity 在 [0.3, 0.7] 区间内的候选对。该区间经验证包含 82.1% 的跨领域论文对，排除了过于相似的同领域配对（>0.7）和完全无关的配对（<0.3）。

Step 4 — 去重：按 (klab_id, arxiv_id) 去重，最终得到 242,253 个候选配对。每篇 KLab 论文平均配对 743 篇 arXiv 论文（最多 1,000 篇）。

3.3 输出

保存为 klab_arxiv_candidates_dedup.csv，包含：klab_idx, klab_id, klab_title, arxiv_idx, arxiv_id, arxiv_title, arxiv_categories, arxiv_year, similarity, in_sweet_spot。

4. 量尺 2：Perplexity 评分

4.1 方法论

基于 Zhang & Evans (2025, arXiv 2509.05591) 的方法。核心思想：如果一篇论文对语言模型来说“更意外”（perplexity 更高），说明它包含更多新颖的信息，可能是更有价值的研究方向。

公式：$PPL(X) = \exp(-1/t \times \Sigma \log p\theta(x_i \mid x_{<i}))$，其中 t 是 token 数量。

4.2 时间分层设计

关键约束：必须只分析模型训练截止日期之后发表的论文，否则论文已在训练数据中，perplexity 不可信。

Batch 1 (2019–2023)：使用 GPT-2（训练截止 2018），处理 114,803 个配对

Batch 2 (2024–2026)：使用 Llama-3-8B（训练截止 2023），处理 127,450 个配对

4.3 实现细节

摘要提取：从原始 arXiv JSON 按需提取每篇论文的摘要（不是从简化版 JSON），确保摘要完整。

批处理：GPT-2 用 batch_size=16，Llama-3 用 batch_size=8（bfloat16 加载）。

断点续传：每 1000 条保存一次，防止 Colab 断线丢失进度。

Bug 修复：第一版代码从简化版 JSON 提取摘要失败，导致所有论文获得相同的 perplexity（因为都在算 'No abstract available.' 的 perplexity）。修复后改为直接从原始 4GB JSON 按需提取。

4.4 结果

Perplexity 分布：mean=27.7, std=21.6, range=[2.4, 1585.6]。高引用 KLab 论文对应的 arXiv 论文 perplexity 显著更高（median 26.7 vs 17.3, $p<0.0001$），验证了 Evans 的理论。

5. 量尺 3：时序收敛分析

5.1 方法

将 297 万篇 arXiv 论文按 (domain, year) 分组，计算每组的 embedding centroid（必须每组至少 10 篇）。然后对每对领域，计算 2019–2026 年间每年的余弦相似度，对时间做线性回归得到 slope。

slope > 0：相似度在升高 = 两个领域在收敛（靠近）

slope < 0：相似度在降低 = 两个领域在发散（远离）

5.2 结果

共得到 190 对领域的通年距离数据（1,520 条记录）。收敛最快的前 3 对：

- eess × physics (slope=+0.0306)：电气工程与物理学快速融合
- cs × physics (slope=+0.0304)：计算机科学与物理学在靠近
- cs × q-bio (slope=+0.0301)：计算机与定量生物学快速收敛

6. 量尺 4：Steering Vector 打分

6.1 方法论

基于 Week 6 课程内容（Contrastive Activation Addition, Turner et al.）。核心思想：通过对比“跨学科论文”和“单学科论文”在 LLM 内部的激活差异，提取一个“跨学科性”方向向量。

公式：h_steer = mean(h_positive) - mean(h_negative)

6.2 正负例构造

正例（30 篇）：KLab 中 cited_by_count > 50 且摘要长度 > 100 字符的高引跨学科论文。数据来源：klab_papers.json（451 篇，有完整摘要）。

负例（30 篇）：从 arXiv JSON 中随机抽取只有单个分类标签且摘要 > 100 字符的论文。

每篇摘要截取前 500 字符，组成 30 个 (positive, negative) 配对。

6.3 关键 Bug 修复

问题 1：klab_metadata.pkl 缺失摘要

klab_metadata.pkl 只包含 abstract_length 字段，没有实际的摘要文本。导致第一版代码用空摘要作为正例，提取出无意义的 steering vector。修复：改用 klab_papers.json（451 篇，有完整摘要）。

问题 2：load_in_8bit 与 steering-vectors 库不兼容

使用 load_in_8bit=True 加载 Llama-3-8B 时，steering-vectors 库的 hook 无法正确捕获激活值，layer_activations 返回空字典。修复：改用 torch_dtype=torch.bfloat16，A100 40GB 完全够用。

问题 3：Cosine similarity 区分度不足

第一版使用 cosine similarity + round(4) 打分，139,292 篇论文只得到 2,985 个唯一分数。修复：改用 dot product（不 round），得到 138,992 个唯一分数，几乎每篇论文一个独立分数。

6.4 最终实现参数

参数	值
模型	Meta-Llama-3-8B (bfloat16)
提取层	Layer 10–21（中间层），最终使用 Layer 15
read_token_index	-1（最后一个 token）
打分方式	dot product (mean pooling of hidden states × steering vector)
批处理大小	batch_size=16

总耗时	提取 ~3 分钟 + 打分 ~25 分钟

6.5 结果

Steering score 分布：mean=0.182, std=0.252, range=[-1.199, +0.768]。唯一分数 138,992 个。

7. 回测验证

7.1 方法

时间回测：用 2019–2022 年的分数预测 2023–2026 年的研究活跃度（以候选配对数量代表）。

历史期：84,891 行，验证期：157,362 行，326 篇 KLab 论文两期都有数据。

7.2 核心发现

量尺	Spearman r	p-value
Steering Score	0.541	< 0.0001
Embedding Similarity	0.413	< 0.0001
Perplexity	0.021	0.711

Steering Vector 对未来研究活跃度的预测力最强（r=0.541），远超表层的 Embedding 距离（r=0.413）和 Perplexity（r=0.021）。这表明 LLM 内部激活模式比表层语义相似度或语言意外度更能捕捉跨学科研究机会的潜力。

7.3 三量尺相关性

三个量尺之间相关性低（最高 Spearman r = -0.270），说明它们捕捉的是不同维度的信息，互补性好。

8. 可视化产出

共产出 9 张图：

fig1_klab_landscape.png：KLab 研究空间 t-SNE 散点图，颜色=领域，大小=引用数

fig2_perplexity_distribution.png：Perplexity 分布对比（高引用 vs 低引用 KLab 论文）

fig3_temporal_trajectory.png：5 对领域的时序距离变化轨迹 (2019–2026)

fig4_convergence_ranking.png：Top 15 收敛最快的领域对排行榜

fig5_sweet_spot_map.png：研究机会“甜蜜点”地图（Novelty × Perplexity × Steering）

fig6_token_activation_full.png：6 篇论文的逐 token Steering Vector 激活热力图

fig6b_token_ranking.png：Top 激活词汇排行（基于真实模型激活值）

fig7_correlation_matrix.png：三量尺 Spearman 相关矩阵

fig8_backtest_and_ranking.png：回测结果 + Top 15 候选排行榜

9. 输出文件说明与使用指南

9.1 主表：scored_all_4metrics.csv

这是第一人的核心产出，其他三人的工作都基于此表。

行数：242,253 行，每行一个 KLab × arXiv 候选配对

KLab 论文数：326 篇

arXiv 论文数：139,292 篇（唯一）

每篇 KLab 平均配对：743 篇 arXiv

列说明

列名	类型	说明
klab_idx	int	KLab 论文索引（0–325）
klab_id	string	OpenAlex ID，如 https://openalex.org/W7118796230
klab_title	string	KLab 论文标题
klab_year	int	发表年份
klab_citations	int	KLab 论文的 OpenAlex 引用数
arxiv_idx	int	arXiv 论文在 embedding 矩阵中的索引
arxiv_id	string	arXiv ID，如 2106.05818
arxiv_title	string	arXiv 论文标题
arxiv_categories	string	arXiv 分类标签，如 cs.CL cs.AI（空格分隔）
arxiv_year	int	发表年份（2019–2026）
similarity	float	KLab 与 arXiv 的余弦相似度（0.17–1.00），越高=越相似
in_sweet_spot	bool	是否在 [0.3, 0.7] 筛选区间内
arxiv_abstract	string	arXiv 论文摘要全文
perplexity	float	GPT-2 或 Llama-3 计算的困惑度（2.4–1585.6），越高=越意外
steering_score	float	Steering Vector dot product（-1.2–+0.77），越高=越跨学科

使用指南

第二人（因果推断）：用 similarity 作为 Treatment 变量（跨领域程度），从 OpenAlex 另外拉取混淆变量（h-index、机构等），做 TARNet/DML 因果推断。

第三人（MCP 封装）：把整张表加载到 Python，按 arxiv_id 或 arxiv_categories 查询，封装成 MCP 工具提供给 ReAct agent。

第四人（LoRA + 奖励模型）：用 perplexity 和 steering_score 作为评估基准，与奖励模型输出对比。

注意事项

- perplexity 和 steering_score 是 arXiv 论文级别的分数，同一篇 arXiv 论文在不同 KLab 配对中分数相同，这是正确行为。
- similarity 是配对级别的分数，同一篇 arXiv 论文与不同 KLab 论文的 similarity 不同。
- 2019–2023 年的 perplexity 用 GPT-2 计算，2024+ 用 Llama-3-8B，两者绝对值不可直接比较，建议分别标准化后再使用。

9.2 辅助表：convergence_yearly.csv

行数：1,520 行

列：domain_1, domain_2, year, cosine_similarity

用途：时序轨迹图的数据源，独立于主表。每行是一对领域在某一年的 embedding centroid 余弦相似度。

9.3 其他文件

klab_papers.json：451 篇 KLab 论文的完整元数据（含摘要、concepts、topics）

klab_embeddings.npz：332 篇 KLab 论文的 384维 embedding 向量

arxiv_embeddings.npz：2,967,989 篇 arXiv 论文的 384维 embedding 向量

steering_vector_v2.pt：Llama-3-8B Layer 10–21 的 steering vector（bfloat16 版）